

Aula 2 - Econometria Financeira 1.

Pedro Albuquerque

Universidade de Brasília

26 de Março de 2018



1 Processos estacionários.

Propriedades.

2 Processo linear

3 Introdução ao processo ARMA.

Propriedades da função de autocorrelação amostral.

4 Previsão de séries temporais.

Propriedades do operador de previsão.

O operador de previsão $\mathcal{P}(Y|\mathbf{w})$.

Algoritmo de Durbin-Levison.

Algoritmo de inovação.



O pressuposto principal da análise de séries temporais é assumir que o processo e suas propriedades (pelo menos alguma delas) não variem com o tempo.

Propriedades básicas: Anteriormente introduzimos o conceito de função de autocovariância de séries temporais, $\{x_t\}$ tal que:

$$\textcircled{1} \quad \gamma(h) = \text{Cov}(X_{t+h}, X_t).$$

$$\textcircled{2} \quad \rho(h) = \gamma(h)/\gamma(0)$$

para $h = 0, \pm 1, \pm 2, \dots$

Essas métricas são úteis na avaliação de processos estacionários, por exemplo suponha $\{X_t\}$ uma série temporal gaussiana, isto é para qualquer coleção de inteiros i_1, \dots, i_n o vetor aleatório $(X_{i_1}, \dots, X_{i_n})^\top$ possui distribuição normal multivariada.

Suponha ainda que observamos X_n , nesse caso qual seria a "melhor" previsão para X_{n+h} ?

Por definição, o "melhor" preditor será aquele que minizar o Erro Quadrático Médio:

$$\text{MSE}(\hat{\theta}) = \mathbb{E}_{\hat{\theta}} \left[(\hat{\theta} - \theta)^2 \right] = \mathbb{V}_{\hat{\theta}}(\hat{\theta}) + \text{Bias}_{\hat{\theta}}(\hat{\theta}, \theta)^2$$



Para isso, seja \mathbf{X} um vetor aleatório com distribuição Normal Multivariada com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias e covariâncias $\Sigma = \Sigma_{\mathbf{xx}}$, de maneira sumarizada $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \Sigma_{\mathbf{xx}})$.

Nesse caso, a função densidade de probabilidade é dada por:

$$f_{\mathbf{X}}(\mathbf{x}) = (2\pi)^{-\frac{n}{2}} |\Sigma|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

Se $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \Sigma_{\mathbf{xx}})$ podemos definir a normal multivariada padronizada \mathbf{Z} fazendo:

$$\mathbf{Z} = \Sigma^{-\frac{1}{2}} (\mathbf{X} - \boldsymbol{\mu})$$



onde $\Sigma^{-\frac{1}{2}}$ é obtido pela inversa da decomposição na forma $\Sigma^{-1} = \mathbf{A}\mathbf{A}^\top$ onde $\mathbf{A} = \Sigma^{-\frac{1}{2}}$.

Nesse caso temos que $\mathbf{Z} \sim N_n(\mathbf{0}, \mathbf{I}_n)$. Suponha agora que possamos particionar nosso vetor aleatório na forma:

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix} \quad (1)$$

tal que:

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix} \sim N_n \left(\begin{bmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right) \quad (2)$$



Nesse formato temos $\boldsymbol{\mu}^{(i)} = \mathbb{E}(\mathbf{X}^{(i)})$ e $\Sigma_{ij} = \mathbb{E}[(\mathbf{X}^{(i)} - \boldsymbol{\mu}^{(i)})(\mathbf{X}^{(j)} - \boldsymbol{\mu}^{(j)})^\top]$.

Se $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ são independentes então $\Sigma_{12} = \Sigma_{21}^\top = \mathbf{0}$. Já a distribuição condicional de $\mathbf{X}^{(1)}|\mathbf{X}^{(2)} = \mathbf{x}^{(2)}$ é dada por:

$$\mathbf{X}^{(1)}|\mathbf{X}^{(2)} = \mathbf{x}^{(2)} \sim N_m(\boldsymbol{\mu}^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}^{(2)} - \boldsymbol{\mu}^{(2)}), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})$$

Particularmente temos:

$$\mathbb{E}[\mathbf{X}^{(1)}|\mathbf{X}^{(2)} = \mathbf{x}^{(2)}] = \boldsymbol{\mu}^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}^{(2)} - \boldsymbol{\mu}^{(2)})$$



Usando essa proposição para nossas séries temporais temos que a distribuição de X_{n+h} dado X_n é:

$$X_{n+h}|X_n \sim N(\mu + \rho(h)(x_n - \mu), \sigma^2(1 - \rho(h)^2))$$

onde μ e σ^2 são as médias e variâncias de X_t . Assim o melhor estimador para a previsão é tal que:

$$\arg \min_{c \in \mathbb{R}} \mathbb{E}[X_{n+h} - c]^2 = \mathbb{E}[X_{n+h}]$$

para um preditor constante.



No caso de um preditor funcional temos:

$$\arg \min_{m(X_n) \in \mathcal{F}} \mathbb{E}[X_{n+h} - m(X_n)]^2 = \sigma^2(1 - \rho(h)^2)$$

Obs: O que acontece se $\rho(h) \rightarrow \pm 1$?

Outra métrica possível é considerar somente os funcionais lineares no espaço de funções $\mathcal{F}_\ell \subset \mathcal{F}$, na forma:

$$\arg \min_{l(X_n) \in \mathcal{F}_\ell} \mathbb{E}[X_{n+h} - (aX_n + b)]^2$$

o qual é mais fácil de ser obtido do que a minimização global do MSE.



UnB

Nesse exemplo o melhor preditor linear é dado por:

$$\ell(X_n) = \mu + \rho(h)(X_n - \mu)$$

o qual fornece MSE igual a:

$$\mathbb{E}[X_{n+h} - \ell(X_n)]^2 = \sigma^2(1 - \rho(h)^2)$$



As propriedades básicas da função de autocovariância são:

- ❶ $\gamma(0) \geq 0$.
- ❷ $|\gamma(h)| \leq \gamma(0) \forall h$
- ❸ $\gamma(h)$ é uma função par, isto é, $\gamma(h) = \gamma(-h)$

A função de autocovariância possui outra propriedade fundamental dada por:

$$\sum_{i=1}^n \sum_{j=1}^n a_i \kappa(i-j) a_j \geq 0$$

para todo inteiro n e vetor real $\mathbf{a} = (a_1, \dots, a_n)^\top$ para qualquer função real $\kappa(\cdot, \cdot)$.



Definição.

Uma série é dita ser estritamente estacionária se

$$(X_1, \dots, X_n)^\top \stackrel{d}{=} (X_{1+h}, \dots, X_{n+h})^\top.$$

Para todos os inteiros h e $n \geq 1$.

Obs: Dizemos que $\{X_t\}$ é fracamente estacionário se $\mathbb{E}(X_t^2) < \infty$ para todo t .

outra maneira mais simples de construir uma série $\{X_t\}$ estritamente estacionária é filtrar uma sequência iid de variáveis aleatórias.

Seja $\{Z_t\}$ uma sequência iid definimos:

$$X_t = g(Z_t, \dots, Z_{t-1}, \dots, Z_{t-q})$$

para alguma função real $g(\cdot, \dots, \cdot)$. Então $\{X_t\}$ será estritamente estacionária também denominada de q -dependente ou q -correlacionada.

Exemplo 2.1

Dizemos que $\{X_t\}$ é um processo de médias móveis de ordem q (MA(q)) se:

$$X_t = Z_t + \theta_1 Z_{t-1} + \cdots + \theta_q Z_{t-q}$$

tal que $\{Z_t\} \sim WN(0, \sigma^2)$ e $\theta_1, \dots, \theta_q$ constantes.

Proposição: Se $\{X_t\}$ é um processo estacionário q -correlacionado com média zero, então esse processo pode ser representado por um processo MA(q).

A classe de modelos de séries temporais lineares, o qual inclui a família ARMA fornece um panorama geral para o estudo dos processos estacionários.

De fato, qualquer processo estacionário de segunda ordem ou é um processo linear ou pode ser transformado em processo linear. Isso é conhecido como **Decomposição de Wold**.

Definição:

A série temporal $\{X_t\}$ é um processo linear se possui a seguinte representação:

$$X_t = \sum_{j=-\infty}^{\infty} \psi_j Z_{t-j}$$

para todo t onde $\{Z_t\} \sim WN(0, \sigma^2)$ e $\{\psi_j\}$ é uma sequência de constantes com $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$.

Em termos do operador de defasagem \mathcal{B} podemos reescrever como

$$X_t = \psi(\mathcal{B})Z_t \text{ onde } \psi(\mathcal{B}) = \sum_{j=-\infty}^{\infty} \psi_j \mathcal{B}^j.$$

O operador $\psi(\mathcal{B})$ pode ser visto como um **filtro linear**, o qual quando aplicado ao ruído branco $\{Z_t\}$ produz como resultado $\{X_t\}$.

Proposição:

Seja $\{Y_t\}$ uma série temporal estacionária com média zero e função de autocovariância γ_y . Se $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$ então a série temporal:

$$X_t = \sum_{j=-\infty}^{\infty} \psi_j Y_{t-j} = \psi(B)Y_t$$

é estacionária com média zero e função de autocovariância:

$$\gamma_x(h) = \sum_{j=-\infty}^{\infty} \sum_{k=-\infty}^{\infty} \psi_j \psi_k \gamma(h + k - j)$$



Note que ainda pelo exemplo anterior temos:

$$Y_t = \phi Y_{t-1} + Z_{t-1} \quad (3)$$

$$= Z_t + \phi Z_{t-1} + \phi^2 Y_{t-2} \quad (4)$$

$$= \vdots \quad (5)$$

$$= Z_t + \phi Z_{t-1} + \cdots + \phi^k Z_{t-k} + \phi^{k+1} Y_{t-k+1} \quad (6)$$

Se $\{Y_t\}$ é um processo estacionário então $\mathbb{E}[Y_t^2]$ é finito e não depende de t , logo:

$$\mathbb{E}[Y_t - \sum_{j=0}^k \phi^j Z_{t-j}]^2 = \phi^{2k+2} \mathbb{E}[Y_{t-k-1}]^2 \rightarrow 0$$

quando $k \rightarrow \infty$. No caso de $|\phi| > 1$ a série não converge.

Seja $\{X_t\}$ um processo ARMA(1,1) então seu PGD é dado por:

$$X_t - \phi X_{t-1} = Z_t + \theta Z_{t-1}$$

onde $\{Z_t\} \sim WN(0, \sigma^2)$ e $\phi + \theta \neq 0$.

Usando o operador de defasagem podemos reescrever na forma:

$$\phi(\mathcal{B})X_t = \theta(\mathcal{B})Z_t$$

onde $\phi(\mathcal{B})$ e $\theta(\mathcal{B})$ são os filtros lineares: $\phi(\mathcal{B}) = 1 - \phi\mathcal{B}$ e $\theta(\mathcal{B}) = 1 + \theta\mathcal{B}$.



O primeiro passo é estudar os valores de ϕ e θ para os quais a solução é estacionária.

Se $|\phi| < 1$, seja $\chi(z)$ a expansão por séries de potência de:

$$\chi(z) = \sum_{j=0}^{\infty} \phi^j z^j$$

o qual possui coeficientes absolutamente somáveis.

No caso do processo ARMA(1,1) concluímos que $\chi(\mathcal{B})\phi(\mathcal{B}) = 1$.
Aplicando $\chi(\mathcal{B})$ dos dois lados temos:

$$\phi(\mathcal{B})X_t = \theta(\mathcal{B})Z_t \quad (7)$$

$$\chi(\mathcal{B})\phi(\mathcal{B})X_t = \chi(\mathcal{B})\theta(\mathcal{B})Z_t \quad (8)$$

$$X_t = \chi(\mathcal{B})\theta(\mathcal{B})Z_t = \phi(\mathcal{B})Z_t \quad (9)$$

$$\psi(B) = \sum_{k=-\infty}^{\infty} \psi_k B^k = (1 + \phi B + \phi^2 B^2 + \dots)(1 + \theta B)$$
 multiplicando
 pelo lado direito temos:

$$\psi_0 = 1, \psi_j = (\phi + \theta)\phi^{j-1} \text{ para } j \geq 1$$

Concluimos que o processo $MA(\infty)$ é a única solução, isto é:

$$X_t = Z_t + (\phi + \theta) \sum_{j=1}^{\infty} \phi^{j-1} Z_{t-j}$$

Agora suponha que $|\phi| > 1$. Assim como anteriormente o primeiro passo é representar $1/\phi(z)$ como uma série de potências de z com coeficientes absolutamente somáveis pela expansão z^{-1} :

$$\chi(z) = - \sum_{j=1}^{\infty} \phi^{-j} z^{-1}$$

então podemos avaliar o mesmo argumento como no caso $|\phi| < 1$ para obter a solução única do processo estacionário.

Seja $\chi(\mathcal{B}) = - \sum_{j=1}^{\infty} \phi^j \mathcal{B}^j$ e aplicando $\chi(\mathcal{B})$ dos dois lados obtemos:



$$X_t = \chi(B)\theta(B)Z_t = -\theta\phi^{-1}Z_t - (\theta + \phi) \sum_{j=1}^{\infty} \phi^{-j-1}Z_{t+j}$$

Se $\phi = \pm 1$ não existe solução estacionária. Consequentemente não há um processo ARMA(1,1) com $\phi = \pm 1$, em resumo para um processo ARMA(1,1):

- ❶ Uma solução estacionária ARMA(1,1) só existe se $\phi \neq \pm 1$.
- ❷ Se $|\phi| < 1$ então a solução estacionária é unicamente dada por

$$X_t = Z_t + (\phi + \theta) \sum_{j=1}^{\infty} \phi^{j-1} Z_{t-j}.$$

Nesse caso dizemos que $\{X_t\}$ é

causado por $\{Z_t\}$ uma vez que X_t pode ser expresso em termos de Z_s para $s \leq t$.



Finalmente, se $|\phi| > 1$ então a solução estacionária é dada por:

$$X_t = \chi(\mathcal{B})\theta(\mathcal{B})Z_t = -\theta\phi^{-1}Z_t - (\theta + \phi) \sum_{j=1}^{\infty} \phi^{-j-1}Z_{t+j}$$

Essa é uma solução **não causal** uma vez que X_t é uma função de Z_s com $s > t$.

Vamos mostrar agora que um processo ARMA(1,1):

$$X_t - \phi X_{t-1} = Z_t + \theta Z_{t-1}$$

com $\{Z_t\} \sim WN(0, \sigma^2)$ e $\phi + \theta \neq 0$ é invertível (e portanto estacionário) se $|\theta| < 1$.



onde

$$\pi(\mathcal{B}) = \sum_{j=0}^{\infty} \pi_j \mathcal{B}^j (1 - \theta \mathcal{B} + (-\theta)^2 \mathcal{B} + \dots)(1 - \phi \mathcal{B})$$

Como $\psi_j = \sum_{k=-\infty}^{\infty} \alpha_k \beta_{j-k} = \sum_{k=-\infty}^{\infty} \beta_k \alpha_{j-k}$ temos:

$$Z_t = X_t - (\phi + \theta) \sum_{j=1}^{\infty} (-\theta)^{j-1} X_{t-j}$$

então, o processo ARMA(1,1) é invertível uma vez que Z_t pode ser expresso em termo dos valores presentes e passados de X_s com $s \leq t$.



Um argumento similar pode ser usado para demonstrar a **não causalidade** quando $|\phi| > 1$ o processo ARMA(1,1) é não-invertível quando $|\theta| > 1$, uma vez que:

$$Z_t = -\phi\theta^{-1}X_t + (\theta + \phi) \sum_{j=1}^{\infty} (-\theta)^{-j-1} X_{t+j}$$

Assim temos que se $|\theta| < 1$ o processo ARMA(1,1) é invertível e Z_t é expresso em termos de X_s $s \leq t$.

Se $\theta > 1$ o processo ARMA(1,1) é não-invertível e Z_t é expresso em termos de X_s com $s \geq t$.



Note que $\gamma(\cdot)$ e $\rho(\cdot)$ são estimados como:

$$\hat{\gamma}(h) = n^{-1} \sum_{t=1}^{n-|h|} (X_{t+|h|} - \bar{X}_n)(X_t - \bar{X}_n)$$

e

$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)}$$

Podemos construir a matriz de autocovariância amostral como:

$$\hat{\Gamma}_k = \begin{bmatrix} \hat{\gamma}(0) & \hat{\gamma}(1) & \dots & \hat{\gamma}(k-1) \\ & \hat{\gamma}(0) & \dots & \vdots \\ & & \ddots & \vdots \\ & & & \hat{\gamma}(0) \end{bmatrix} \quad (13)$$

De igual modo a matriz de autocorrelação é construída por:

$$\hat{R}_k = \frac{\hat{\Gamma}_k}{\hat{\gamma}(0)}$$

Box e Jenkins (1976) p. 33 sugere que se use $n \geq 0$ e $h \leq n/4$.



UnB

A distribuição amostral é dada por $\hat{\rho}_k \sim N(\hat{\rho}_k, n^{-1}W)$ com $\hat{\rho} = (\hat{\rho}(1), \dots, \hat{\rho}(k))$

e W é a matriz obtida pela fórmula de Bartlett:

$$W_{ij} = \sum_{k=1}^{\infty} \{\rho(k+i) + \rho(k-i) - 2\rho(i)\rho(k)\} \{\rho(k+j) + \rho(k-j) - 2\rho(j)\rho(k)\}$$

Exemplo 2.3

Considere a série elec.txt calcule a distribuição amostral da autocorrelação usando o R.

Agora vamos considerar o problema de previsão para X_{n+h} e $h \geq 0$ de uma série estacionária com média μ e função de autocovariância $\gamma(\cdot)$ em termos dos valores de $\{X_n, \dots, X_1\}$.

O objetivo é encontrar a combinação linear de $1, X_n, X_{n-1}, \dots, X_1$ para prever X_{n+h} com o menor MSE possível.

O melhor preditor linear em termos de $1, X_n, X_{n-1}, \dots, X_1$ será denotado por $\mathcal{P}_n X_{n+h} = a_0 + a_1 X_n + \dots + a_n X_1$ onde o processo é:

$$\arg \min_{\mathbf{a} \in \mathbb{R}^{n+1}} \mathbb{E}[(X_{n+h} - a_0 - a_1 X_n - \dots - a_n X_1)^2]$$



Para resolver esse problema derivamos e igualamos a zero, obtendo assim o sistema:

$$\begin{cases} \mathbb{E} \left[X_{n+h} - a_0 - \sum_{i=1}^n a_i X_{n+1-i} \right] = 0 \\ \mathbb{E} \left[\left(X_{n+h} - a_0 - \sum_{i=1}^n a_i X_{n+1-i} \right) X_{n+1-j} \right] = 0 \end{cases} \quad (14)$$

para $j = 1, \dots, n$. Essas equações podem ser escritas na forma $a_0 = \mu(1 - \sum_{i=1}^n a_i)$ e $\Gamma_n \mathbf{a}_n = \gamma_n(h)$.

Nesse caso temos $\gamma_n(h) = (\gamma(h), \gamma(h+1), \dots, \gamma(h+n-1))^T$ e portanto $\mathcal{P}_n X_{n+h} = \mu + \sum_{i=1}^n a_i (X_{n+1-i} - \mu)$, onde \mathbf{a}_n satisfaz $\Gamma_n \mathbf{a}_n = \gamma_n(h)$.



Exemplo 2.4

Simule um processo AR(1) com 1000 observações e faça a melhor previsão linear para as últimas observações usando como base as 950 primeiras.

Faça isso usando o R.

Para o operador de previsão temos as seguintes propriedades:

- 1 $\mathcal{P}_n X_{n+h} = \mu + \sum_{i=1}^n a_i (X_{n+1-i} - \mu).$
- 2 $\mathbb{E}[X_{n+h} - \mathcal{P}_n X_{n+h}]^2 = \gamma(0) - \mathbf{a}_n^\top \boldsymbol{\gamma}_n(h).$
- 3 $\mathbb{E}(X_{n+h} - \mathcal{P}_n X_{n+h}) = 0.$
- 4 $\mathbb{E}[(X_{n+h} - \mathcal{P}_n X_{n+h})X_j] = 0, j = 1, \dots, n.$

Exemplo 2.5

Considere uma série estacionária AR(1) com P.G.D dado por $X_t = \phi X_{t-1} + Z_t$ onde $|\phi| < 1$ e $Z_t \sim RB(0, \sigma^2)$ encontre o melhor preditor linear e seu erro-quadrático médio.

Suponha que Y e W_n, \dots, W_1 sejam quaisquer variáveis aleatórias com segundo momento finito e médias $\mu = \mathbb{E}(Y)$, $\mu_i = \mathbb{E}(W_i)$ e covariâncias dadas por $Cov(Y, Y)$, $Cov(Y, W_i)$ e $Cov(W_i, W_j)$ postuladas serem conhecidas.

Podemos escrever na forma matricial $\mathbf{W} = (W_n, \dots, W_1)^\top$ com vetor de médias $\boldsymbol{\mu}_\mathbf{W} = (\mu_n, \dots, \mu_1)^\top$ e covariâncias:

$$\boldsymbol{\gamma} = Cov(Y, \mathbf{W}) = [Cov(Y, W_n), \dots, Cov(Y, W_1)]^\top$$

com matriz:

$$\boldsymbol{\Gamma} = Cov(\mathbf{W}, \mathbf{W})$$



Usando a mesma argumentação é possível mostrar que o melhor preditor linear é dado por:

$$\mathcal{P}(Y|\mathbf{W}) = \mu_Y + \mathbf{a}^\top (\mathbf{W} - \mu_{\mathbf{W}})$$

onde $\mathbf{a} = (a_1, \dots, a_n)^\top$ é ma solução do sistema:

$$\Gamma \mathbf{a} = \gamma$$

Exemplo 2.6

Considere uma série estacionária AR(1) com P.G.D dado por $X_t = \phi X_{t-1} + Z_t$ onde $|\phi| < 1$ e $Z_t \sim RB(0, \sigma^2)$. Suponha que observamos X_1, X_3 mas não X_2 encontre o melhor preditor linear para X_2 e seu erro-quadrático médio.

O operador de previsão $\mathcal{P}(Y|\mathbf{W})$.

Para $\mathbf{W} = (W_n, \dots, W_1)^\top$ e Y com segundo momento finito, vimos como calcular o melhor preditor linear de Y em termos de W_n, \dots, W_1 .

A função $\mathcal{P}(\cdot|\mathbf{W})$ a qual converte Y em $\mathcal{P}(Y|\mathbf{W})$ é denominado **operador de previsão**, cujas propriedades são dadas a seguir. Suponha que $\mathbb{E}(U^2) < \infty$, $\mathbb{E}(V^2) < \infty$, $\Gamma = \text{Cov}(\mathbf{W}, \mathbf{W})$ e $\beta, \alpha_1, \dots, \alpha_n$ são constantes então:

- ① $\mathcal{P}(U|\mathbf{W}) = \mathbb{E}(U) + \mathbf{a}^\top (\mathbf{W} - \mathbb{E}(\mathbf{W}))$ onde $\Gamma \mathbf{a} = \text{Cov}(U, \mathbf{W})$.
- ② $\mathbb{E}[(U - \mathcal{P}(U|\mathbf{W}))\mathbf{W}] = \mathbf{0}$ e $\mathbb{E}[U - \mathcal{P}(U|\mathbf{W})] = 0$.
- ③ $\mathbb{E}[(U - \mathcal{P}(U|\mathbf{W}))^2] = \mathbb{V}(U) - \mathbf{a}^\top \text{Cov}(U, \mathbf{W})$.
- ④ $\mathcal{P}(\alpha_1 U + \alpha_2 V + \beta|\mathbf{W}) = \alpha_1 \mathcal{P}(U|\mathbf{W}) + \alpha_2 \mathcal{P}(V|\mathbf{W}) + \beta$.
- ⑤ $\mathcal{P}(\sum_{i=1}^n \alpha_i W_i + \beta|\mathbf{W}) = \sum_{i=1}^n \alpha_i W_i + \beta$.
- ⑥ $\mathcal{P}(U|\mathbf{W}) = \mathbb{E}(U)$ se $\text{Cov}(U, \mathbf{W}) = \mathbf{0}$.
- ⑦ $\mathcal{P}(U|\mathbf{W}) = \mathcal{P}(\mathcal{P}(U|\mathbf{W}, \mathbf{V})|\mathbf{W})$ se \mathbf{V} é um vetor aleatório tal que $\mathbb{E}(\mathbf{V}\mathbf{V}^\top) < \infty$

Exemplo 2.7

Seja a série temporal $\{Y_t\}$ com P.G.D AR(1) com média μ . Seja $\{X_t = Y_t - \mu\}$ um processo AR(1) com média zero mostre que:

$$Y_t - \mu = \phi(Y_{t-1} - \mu) + Z_t$$

Encontre o melhor preditor linear para $\mathcal{P}_n Y_{n+h}$

Uma vez que $\mathcal{P}(Y|\mathbf{W}) = \mu_Y + \mathbf{a}^\top(\mathbf{W} - \mu_{\mathbf{W}})$ e $\Gamma\mathbf{a} = \gamma$ podemos construir um algoritmo para estimar os parâmetros dos modelos de séries temporais lineares, como:

$$\mathcal{P}_n X_{n+1} = \phi_n^\top X_n = \phi_{n1} X_n + \cdots + \phi_{nn} X_1 \quad (15)$$

onde $\phi_n = \Gamma_n^{-1} \gamma_n$ tal que $\gamma_n(\gamma(1), \dots, \gamma(n))^\top$ com erro quadrático médio dado por:

$$\nu_n = \mathbb{E}[X_{n+1} - \mathcal{P}_n X_{n+1}]^2 = \gamma(0) - \phi_n^\top \gamma_n$$



Os coeficientes $\phi_{n1}, \dots, \phi_{nn}$ podem ser computados recursivamente por meio dos passos:

$$\textcircled{1} \quad \phi_{nn} = [\gamma(n) - \sum_{j=1}^{n-1} \phi_{n-1,j} \gamma(n-j)] \nu_{n-1}^{-1}.$$

$\textcircled{2}$

$$\begin{bmatrix} \phi_{n1} \\ \vdots \\ \phi_{n,n-1} \end{bmatrix} = \begin{bmatrix} \phi_{n-1,1} \\ \vdots \\ \phi_{n-1,n-1} \end{bmatrix} - \phi_{nn} \begin{bmatrix} \phi_{n-1,n-1} \\ \vdots \\ \phi_{n-1,1} \end{bmatrix} \quad (16)$$

tal que $\nu_n = \nu_{n-1}[1 - \phi_{nn}^2]$ onde $\phi_{11} = \gamma(1)/\gamma(0)$ com $\nu_0 = \gamma(0)$.

Exemplo 2.8

Usando a série simulada encontre os coeficientes de previsão usando o Algoritmo de Durbin-Levison no R.

Outro algoritmo importante que pode ser aplicado a qualquer série temporal com segundo momento finito sendo estacionária ou não, é o **algoritmo de inovação**.

Suponha que $\{X_t\}$ é uma série com média zero e $\mathbb{E}(|X_t|^2) < \infty$ para cada t , seja $\mathbb{E}(X_i X_j) = \kappa(i, j)$ podemos introduzir a seguinte variável:

$$\hat{X}_n = \begin{cases} 0, & \text{se } n = 1 \\ \mathcal{P}_{n-1} X_n, & \text{se } n = 2, 3, \dots \end{cases} \quad (17)$$

$$\text{e } \kappa_n = \mathbb{E}[X_{n+1} - \mathcal{P}_n X_{n+1}]^2.$$

As inovações ou erros de previsão de 1 passo são definidas como:

$$U_n = X_n - \hat{X}_n$$

Na forma matricial temos $\mathbf{U}_n = (U_1, \dots, U_n)^\top$ e $\mathbf{X}_n = (X_1, \dots, X_n)^\top$.
Podemos então escrever:

$$\mathbf{U}_n = \mathbf{A}_n \mathbf{X}_n$$

onde \mathbf{A}_n possui a forma:



$$\mathbf{A}_n = \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ a_{11} & 1 & 0 & \dots & 0 \\ a_{22} & a_{21} & 1 & \dots & 0 \\ \vdots & \dots & \ddots & \vdots & \\ a_{n-1,n-1} & a_{n-1,n-2} & a_{n-1,n-3} & \dots & 1 \end{bmatrix} \quad (18)$$

Se $\{X_t\}$ é estacionário $a_{ij} = -a_j$ com a_j obtido por $\Gamma_n \mathbf{a}_n = \gamma_n(h)$ com $h = 1$.

Isso implica que \mathbf{A}_n é não singular com inversa dada por:

$$\mathbf{C}_n = \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ \theta_{11} & 1 & 0 & \dots & 0 \\ \theta_{22} & a_{21} & 1 & \dots & 0 \\ \vdots & \dots & \ddots & \vdots & \\ \theta_{n-1,n-1} & \theta_{n-1,n-2} & \theta_{n-1,n-3} & \dots & 1 \end{bmatrix} \quad (19)$$

O vetor de previsões de 1 passo $\hat{\mathbf{X}}_n = (X_1, \mathcal{P}_1 X_2, \dots, \mathcal{P}_{n-1} X_n)^\top$ pode ser expresso como:

$$\hat{\mathbf{X}}_n = \mathbf{X}_n - \mathbf{U}_n = \mathbf{C}_n \mathbf{U}_n - \mathbf{U}_n = \Theta_n (\mathbf{X}_n - \hat{\mathbf{X}}_n) \quad (20)$$



A equação 20 pode ser reescrita como:

$$\hat{X}_{n+1} = \begin{cases} 0 & \text{se } n = 0 \\ \sum_{j=1}^n \theta_{nj}(X_{n+1-j} - \hat{X}_{n+1-j}) & \text{para } n = 1, 2, \dots \end{cases} \quad (21)$$

Para os quais as previsões 1 passo podem ser computadas como $\hat{X}_1, \hat{X}_2, \dots$ recursivamente usando os coeficientes θ_{ij} . O Algoritmo é definido pelos passos:

$$\textcircled{1} \nu_0 = \kappa(1, 1)$$

$$\textcircled{2} \theta_{n,n-k} = \nu_k^{-1} \left(\kappa(n+1, k+1) - \sum_{j=0}^{k-1} \theta_{k,k-j} \theta_{n,n-j} \nu_j \right) \text{ para}$$

$$0 \leq k \leq n$$



$$e \nu_n = \kappa(n+1, n+1) - \sum_{j=0}^{n-1} \theta_{n,n-j}^2 \nu_j$$

Exemplo 2.8

Considere uma série $\{X_t\}$ definida como:

$$X_t = Z_t + \theta Z_{t-1}$$

onde $\{Z_t\} \sim WN(0, \sigma^2)$. Vimos anteriormente que $\kappa(i, j) = 0$ para $|i - j| > 1$, $\kappa(i, i) = \sigma^2(1 + \theta^2)$ e $\kappa(i, i + 1) = \theta\sigma^2$. Aplique o algoritmo de inovação.

Para a previsão h passos a frente podemos usar o resultado:

$$\mathcal{P}_n(X_{n+k} - \mathcal{P}_{n+k-1}X_{n+k}) = 0 \text{ para } k \geq 1$$

Como $\mathbb{E}(\text{Erro} \times \text{Variável de previsão}) = 0$ e sabendo que:

$$\mathbb{E}[(X_{n+k} - \mathcal{P}X_{n+k} - 0)X_{n+j-1}] = 0 \text{ para } j = 1, \dots, n$$

temos:

$$\mathcal{P}_n X_{n+h} = \mathcal{P}_n \mathcal{P}_{n+h-1} X_{n+h} = \mathcal{P}_n \hat{X}_{n+h}$$

o qual é igual a:

$$\mathcal{P}_n \left(\sum_{j=1}^{n+h-1} \theta_{n+h-1,j} (X_{n+h-j} - \hat{X}_{n+h-j}) \right)$$

Usando a linearidade do operador \mathcal{P}_n temos:

$$\mathcal{P}_n X_{n+h} = \sum_{j=h}^{n+h-1} \theta_{n+h-1,j} (X_{n+h-j} - \hat{X}_{n+h-j})$$

onde os coeficientes θ_{nj} são determinados pelo algoritmo de inovação.

